


ĐẠI HỌC HUẾ
TRƯỜNG ĐẠI HỌC KHOA HỌC
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO NIÊN LUẬN

Học phần: Thực tập viết niên luận (TIN3142)

ĐỀ TÀI:
DỰ BÁO XU HƯỚNG GIÁ BTC/USDT 24 GIỜ
TIẾP THEO DỰA TRÊN KIẾN TRÚC
TRANSFORMER KẾT HỢP VỚI PHÂN TÍCH
CẢM XÚC TIÊU ĐỀ TIN TỨC CHUYÊN NGÀNH

Giảng viên hướng dẫn:	Lê Quang Chiến
Sinh viên thực hiện:	Trần Hữu Minh Duy
Mã số sinh viên:	23T1020134
Lớp:	CNTT K47I

Thừa Thiên Huế, Năm 2026

Mục lục

1	Tổng quan về đề tài và Xác định mục tiêu	2
1.1	Lý do chọn đề tài (Đặt vấn đề thực tế)	2
1.2	Đối tượng và phạm vi nghiên cứu	3
1.2.1	Đối tượng nghiên cứu	3
1.2.2	Phạm vi nghiên cứu	4
1.3	Mục tiêu của nghiên cứu	4
1.3.1	Mục tiêu chính	4
1.3.2	Chỉ số thành công (Success Metrics)	5
1.4	Tổng quan về các công trình nghiên cứu liên quan	5
1.4.1	Dự báo chuỗi thời gian tài chính bằng học sâu	5
1.4.2	Phân tích cảm xúc tin tức (Sentiment Analysis) trong tài chính	6
1.4.3	Hybrid Approaches: Kết hợp kỹ thuật + Sentiment	6
1.4.4	Khoảng trống nghiên cứu (Research Gap)	6
2	Cơ sở lý thuyết và Xây dựng bộ dữ liệu	8
2.1	Cơ sở lý thuyết	8
2.1.1	Kiến trúc Transformer cho dự báo chuỗi thời gian	8
2.1.2	Mô hình ngôn ngữ lớn BERT trong phân tích cảm xúc văn bản tin tức	11
2.1.3	Attention Fusion Layer: Tích hợp đồng bộ tín hiệu đa phương thức	11
2.2	Xây dựng và mô tả chi tiết bộ dữ liệu	12
2.2.1	Nguồn gốc và quy trình thu thập dữ liệu	12
2.2.2	Quy trình tiền xử lý dữ liệu (Data Preprocessing Pipeline)	13
2.2.3	Cấu trúc chi tiết không gian đặc trưng (Features Structure)	14
2.2.4	Thống kê và Phân chia phân lớp bộ dữ liệu	15
	Tài liệu tham khảo	17

Chương 1

Tổng quan về đề tài và Xác định mục tiêu

1.1 Lý do chọn đề tài (Đặt vấn đề thực tế)

Thị trường tiền điện tử đã trở thành một loại tài sản đầu tư quan trọng với quy mô khổng lồ, trong đó Bitcoin (BTC) là tài sản chủ chốt chiếm tỷ trọng vốn hóa lớn nhất và đóng vai trò dẫn dắt tâm lý toàn thị trường [4]. Theo báo cáo từ tổ chức Triple-A, Việt Nam hiện đang thuộc nhóm các quốc gia có tỷ lệ áp dụng tài sản số cao hàng đầu với hơn 21.2% dân số sở hữu tiền điện tử [13].

Tuy nhiên, Bitcoin có đặc thù là biến động giá cực kỳ mạnh (High Volatility), chịu ảnh hưởng phức tạp bởi nhiều yếu tố: dữ liệu kỹ thuật (giá, khối lượng), tin tức thị trường, và tâm lý nhà đầu tư. Khi xảy ra sự kiện tin tức lớn—ví dụ như Ủy ban SEC (Mỹ) phê duyệt Bitcoin ETF, hay một sàn giao dịch bị hack—thông tin này lan truyền nhanh chóng trên các trang tin tức chuyên ngành (CoinDesk, CoinTelegraph), làm thay đổi tâm lý nhà đầu tư và kéo theo biến động giá trong vòng vài giờ. Tuy nhiên, việc con người theo dõi và phân tích thủ công hàng trăm tiêu đề tin tức hàng ngày để tìm ra tín hiệu thị trường là bất khả thi.

Các phương pháp phân tích kỹ thuật truyền thống hoặc mô hình thống kê toán học cổ điển thường thất bại trong việc nắm bắt các mô hình phi tuyến tính phức tạp của Bitcoin, đặc biệt là khi bỏ qua yếu tố tin tức [11]. Gần đây, các mô hình học sâu, đặc biệt là kiến trúc Transformer, đã chứng minh ưu thế vượt trội trong dự báo chuỗi thời gian tài chính. Nghiên cứu cho thấy Transformer đạt độ chính xác cao hơn LSTM truyền thống do khả năng nắm bắt phụ thuộc dài hạn tốt hơn nhờ cơ chế Self-Attention [14].

Hơn nữa, công nghệ NLP hiện đại như BERT (Bidirectional Encoder Representations from Transformers) [7] cho phép phân tích tự động cảm xúc (sentiment) của tin tức với độ chính xác cao (>90%). Một số nghiên cứu gần đây đã chứng minh tương quan mạnh giữa sentiment tin tức và biến động giá tiền điện tử: tin tích cực thường dẫn đến tăng giá, trong khi tin tiêu cực dẫn đến giảm giá ngắn hạn.

Do đó, xây dựng hệ thống dự báo ****kết hợp hai loại dữ liệu**** (kỹ thuật + sentiment tin tức) sử dụng Transformer và BERT là cấp thiết để:

1. Nắm bắt mô hình phi tuyến tính từ chuỗi giá OHLCV
2. Trích xuất tự động cảm xúc từ tin tức chuyên ngành
3. Kết hợp cả hai nguồn thông tin để cải thiện độ chính xác dự báo

1.2 Đối tượng và phạm vi nghiên cứu

1.2.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu là **xu hướng biến động giá ngắn hạn** cặp tài sản BTC/USDT trong vòng 24 giờ tiếp theo (tăng hoặc giảm). Xu hướng này được định lượng hóa thông qua sự kết hợp hai loại dữ liệu đa phương thức:

- **Dữ liệu chuỗi thời gian OHLCV (kỹ thuật):** Chuỗi thời gian chứa giá mở cửa (Open), cao nhất (High), thấp nhất (Low), đóng cửa (Close) và khối lượng giao dịch (Volume) của cặp BTC/USDT từ sàn giao dịch Binance [2] với chu kỳ 1 giờ (hourly candles).

Các đặc trưng kỹ thuật được trích xuất bao gồm:

- Chỉ số RSI (Relative Strength Index): đo lường cường độ mua/bán
 - Chỉ số MACD (Moving Average Convergence Divergence): theo dõi xu hướng
 - Bollinger Bands: xác định mức hỗ trợ/kháng cự
 - Trung bình động SMA 7, 14, 21 ngày: xác định xu hướng trung hạn
 - Volatility (độ biến động): đo lường rủi ro
- **Dữ liệu tiêu đề tin tức và phân tích cảm xúc (NLP):** Tập hợp tiêu đề tin tức từ các cổng tin chuyên ngành Crypto được thu thập hàng ngày từ:
 - CoinDesk [3] (<https://www.coindesk.com>)
 - CoinTelegraph [6] (<https://cointelegraph.com>)
 - The Block [12] (<https://www.theblock.co>)

Mỗi tiêu đề được xử lý bằng mô hình **BERT (Bidirectional Encoder Representations from Transformers)** để trích xuất:

- Sentiment Score: cảm tính tích cực (+1), tiêu cực (-1), hoặc trung lập (0)
- Confidence Score: độ tin cậy của dự đoán cảm xúc
- Aggregated Sentiment Index: tổng hợp cảm xúc hàng ngày/hàng giờ

Ví dụ:

- Tin tích cực: "SEC phê duyệt Bitcoin Spot ETF" → Sentiment = +0.95
- Tin tiêu cực: "Sàn giao dịch FTX vỡ nợ, mất 8 tỷ USD" → Sentiment = -0.90
- Tin trung lập: "Nhà khoa học phát triển công nghệ Blockchain mới" → Sentiment = 0.10

Biến mục tiêu (Target): Nhãn nhị phân dự báo giá 24h tiếp theo:

$$y = \begin{cases} 1 & \text{nếu } P_{t+24h} > P_t \text{ (giá tăng)} \\ 0 & \text{nếu } P_{t+24h} \leq P_t \text{ (giá giảm/đi ngang)} \end{cases}$$

1.2.2 Phạm vi nghiên cứu

- **Tài sản mục tiêu:** Cặp giao dịch **BTC/USDT (Bitcoin/Tether)** trên sàn Binance—cặp có khối lượng giao dịch lớn nhất thế giới, dữ liệu lịch sử ổn định và dễ tiếp cận qua API công khai [5].
- **Thời gian dữ liệu:** Dữ liệu OHLCV hourly từ ngày 01/01/2024 đến 01/07/2026, tương đương khoảng 17.500 bản ghi; dữ liệu tin tức tương ứng (1.500-2.000 tiêu đề).
- **Kiến trúc AI áp dụng:**
 - **Module 1 - Time Series AI:** Transformer Encoder-Decoder để xử lý chuỗi OHLCV và các chỉ số kỹ thuật
 - **Module 2 - NLP AI:** BERT (hoặc DistilBERT) để phân tích cảm xúc tiêu đề tin tức → tính Sentiment Score cho mỗi bản ghi
 - **Module 3 - Fusion Layer:** Attention-based fusion layer để kết hợp output từ Module 1 (tín hiệu kỹ thuật) + Module 2 (tín hiệu sentiment) → dự báo cuối cùng
- **Loại bài toán:** Phân loại nhị phân (Binary Classification)—dự báo xu hướng tăng/giảm trong 24h, **KHÔNG** dự báo giá tuyệt đối.
- **Không bao gồm:**
 - Chỉ số kinh tế vĩ mô toàn cầu (lạm phát, lãi suất Fed, GDP)
 - Dự báo của chuyên gia tài chính
 - Phân tích On-chain phức tạp (tx count, active addresses)
 - Dữ liệu từ mạng xã hội (Twitter/X, Reddit)

1.3 Mục tiêu của nghiên cứu

1.3.1 Mục tiêu chính

1. **So sánh hiệu suất giữa Transformer và LSTM:** Triển khai và huấn luyện cả mô hình Transformer Encoder-Decoder và LSTM truyền thống trên cùng tập dữ liệu OHLCV, so sánh các chỉ số: Accuracy, Precision, Recall, F1-Score, ROC-AUC.
Mục tiêu: Chứng minh Transformer vượt trội LSTM ít nhất 3-5% về Accuracy.
2. **Định lượng tác động của phân tích cảm xúc tin tức:** Huấn luyện mô hình Transformer theo hai cách:
 - (a) Baseline A: Chỉ sử dụng dữ liệu OHLCV kỹ thuật
 - (b) Baseline B: Kết hợp OHLCV + Sentiment Score từ tin tứcSo sánh hiệu suất: Accuracy(OHLCV + Sentiment) vs Accuracy(OHLCV only).
Mục tiêu: Chứng minh rằng thêm sentiment làm tăng độ chính xác ít nhất 2-3%.
3. **Xây dựng và đánh giá mô hình Transformer Fusion (Two-Modal AI):** Thiết kế kiến trúc hybrid kết hợp:

- Transformer cho dữ liệu OHLCV
- BERT cho cảm xúc tin tức
- Attention Fusion Layer kết hợp hai tín hiệu

Mục tiêu: Mô hình đạt Accuracy $\geq 75\%$ trên tập kiểm tra (Test Set).

4. **Triển khai dashboard tương tác:** Xây dựng ứng dụng web bằng Streamlit hoặc Jupyter Dashboard để:

- Hiển thị dự báo 24h tiếp theo (tăng/giảm + xác suất)
- Trực quan hóa chỉ số kỹ thuật hiện tại (RSI, MACD, Bollinger, SMA)
- Hiển thị sentiment tin tức hôm nay (tích cực/tiêu cực/trung lập)
- Vẽ biểu đồ lịch sử: dự báo vs giá thực tế (backtest)

1.3.2 Chỉ số thành công (Success Metrics)

Tiêu chí	Target	Ghi chú
Accuracy (Test Set)	$\geq 75\%$	Chỉ tiêu chính
F1-Score	≥ 0.72	Cân bằng Precision/Recall
ROC-AUC	≥ 0.80	Khả năng phân biệt lớp
Transformer > LSTM	$\Delta Acc \geq +3\%$	So sánh baseline
Sentiment Contribution	$\Delta Acc \geq +2\%$	Tác động tin tức
Dataset (OHLCV)	≥ 2.000 samples	17.500 ✓
Dataset (News)	≥ 1.000 headlines	1.500-2.000 ✓
Dashboard	Hoạt động	Realtime prediction

1.4 Tổng quan về các công trình nghiên cứu liên quan

1.4.1 Dự báo chuỗi thời gian tài chính bằng học sâu

Dự báo chuỗi thời gian là bài toán cổ điển trong machine learning. Mạng LSTM (Long Short-Term Memory) được Hochreiter và Schmidhuber (1997) [9] giới thiệu để giải quyết vấn đề vanishing gradient trong RNN truyền thống, cho phép mô hình ghi nhớ thông tin trong chuỗi dài.

Nelson et al. (2017) [11] áp dụng LSTM để dự báo giá cổ phiếu S&P 500 và đạt sai số MSE = 0.0089. Tuy nhiên, LSTM có những hạn chế:

- Xử lý tuần tự (sequential) nên tốc độ huấn luyện chậm
- Khó nắm bắt phụ thuộc rất dài hạn khi chuỗi vượt 100+ bước thời gian

Vaswani et al. (2017) [14] giới thiệu kiến trúc Transformer với cơ chế Self-Attention Mechanism, cho phép mô hình:

- Xử lý toàn bộ chuỗi song song (parallelization) $\rightarrow$ tốc độ huấn luyện nhanh hơn 10-100 lần so với LSTM

- Nắm bắt phụ thuộc dài hạn tốt hơn nhờ attention weights có thể học được

Áp dụng Transformer cho dự báo giá crypto ngắn hạn (24h) cho thấy kết quả vượt trội: $MSE = 0.0051$ (so với LSTM $MSE = 0.0089$), tương đương cải thiện độ chính xác khoảng 12-15%.

1.4.2 Phân tích cảm xúc tin tức (Sentiment Analysis) trong tài chính

Sentiment Analysis là quá trình trích xuất cảm xúc (tích cực/tiêu cực/trung lập) từ văn bản. Go et al. (2009) [8] sử dụng Naive Bayes và SVM cho phân loại cảm xúc trên Twitter, đạt độ chính xác 82-85%.

Gần đây, BERT (Bidirectional Encoder Representations from Transformers) của Devlin et al. (2019) [7] đã cách mạng hóa NLP. BERT được pre-train trên một lượng văn bản khổng lồ (2.5 tỷ token), cho phép hiểu ngữ cảnh hai chiều (bidirectional), đạt hiệu suất tốt nhất trên hầu hết các bài toán NLP, bao gồm Sentiment Analysis với độ chính xác $>90\%$.

Một số nghiên cứu gần đây tìm thấy tương quan mạnh giữa sentiment tin tức và biến động giá tiền điện tử:

- Tin tích cực (ví dụ: "SEC phê duyệt Bitcoin ETF") $\rightarrow$ giá tăng trong 24-48h tiếp theo
- Tin tiêu cực (ví dụ: "Sàn giao dịch bị hack", "Nhà nước cấm crypto") $\rightarrow$ giá giảm trong vài giờ

Krauss et al. (2017) [10] áp dụng Deep Neural Networks cho dự báo forex high-frequency và chứng minh rằng thêm các loại dữ liệu bổ sung (bên ngoài giá) cải thiện độ chính xác.

1.4.3 Hybrid Approaches: Kết hợp kỹ thuật + Sentiment

Một số công trình gần đây bắt đầu kết hợp dữ liệu kỹ thuật (giá, khối lượng) với dữ liệu văn bản (tin tức, sentiment):

- Bui et al. (2021) kết hợp LSTM + Sentiment Analysis để dự báo giá cổ phiếu, đạt $Accuracy = 78\%$, vượt trội LSTM only ($Accuracy = 72\%$)
- Alameer et al. (2021) [1] sử dụng Multi-task Learning để dự báo giá dầu thô kết hợp tin tức và dữ liệu kỹ thuật

Tuy nhiên, các công trình trên chủ yếu sử dụng LSTM chứ không phải Transformer. Việc kết hợp **Transformer (chứ không phải LSTM) + BERT Sentiment Analysis** cho dự báo giá Bitcoin/USDT ngắn hạn (24h) vẫn còn là khoảng trống trong ngành.

1.4.4 Khoảng trống nghiên cứu (Research Gap)

Từ tổng quan trên, chúng tôi nhận thấy:

1. **Transformer chưa được so sánh chi tiết với LSTM** trên bài toán dự báo Bitcoin 24h với dữ liệu sạch từ Binance, dùng cùng hyperparameters

2. **Sự kết hợp Two-Modal AI (Transformer + BERT Sentiment)** cho dự báo giá BTC/USDT ngắn hạn **chưa có công trình học thuật tương tự**
3. **Chưa có định lượng rõ ràng** về tác động định lượng (incremental improvement) của tin tức (sentiment) đối với độ chính xác dự báo giá crypto ngắn hạn
4. **Ứng dụng dashboard tương tác** kết hợp dự báo + hiển thị sentiment tin tức thời gian thực **chưa phổ biến** trong cộng đồng crypto

Đề tài này nhằm **lấp đầy những khoảng trống trên** bằng cách:

1. Xây dựng Transformer + BERT Sentiment kết hợp (Two-Modal AI)
2. So sánh hiệu suất với LSTM baseline
3. Định lượng đóng góp của Sentiment đối với dự báo
4. Triển khai ứng dụng dashboard tương tác hỗ trợ nhà đầu tư

Chương 2

Cơ sở lý thuyết và Xây dựng bộ dữ liệu

2.1 Cơ sở lý thuyết

2.1.1 Kiến trúc Transformer cho dự báo chuỗi thời gian

Tổng quan về Transformer

Transformer là một kiến trúc học sâu đột phá được giới thiệu bởi Vaswani et al. (2017) [14] thông qua công trình "Attention is All You Need". Khác với các kiến trúc mạng hồi quy truyền thống (RNN, LSTM, GRU) xử lý chuỗi dữ liệu một cách tuần tự và chịu giới hạn về bộ nhớ, Transformer loại bỏ hoàn toàn cấu trúc tuần tự này, cho phép tính toán song song hóa (parallelization) toàn bộ chuỗi dữ liệu đầu vào. Sự thay đổi mang tính bản lề này mang lại các ưu thế vượt trội:

- **Tối ưu hóa hiệu suất tính toán:** Tốc độ huấn luyện và hội tụ nhanh hơn từ 10 đến 100 lần so với mạng LSTM truyền thống [9] trên cùng một cấu hình phần cứng xử lý đồ họa (GPU).
- **Khả năng thu giữ phụ thuộc dài hạn (Long-term Dependency):** Cơ chế Tự chú ý (Self-Attention) thiết lập đường truyền thông tin trực tiếp giữa hai điểm bất kỳ trong chuỗi chu kỳ, bất kể khoảng cách thời gian.
- **Triệt tiêu hiện tượng suy giảm Gradient:** Cơ chế kết nối tắt (Residual Connections) kết hợp chuẩn hóa tầng (Layer Normalization) giúp luồng đạo hàm truyền ổn định qua các lớp sâu mà không bị tiêu biến (vanishing) hay bùng nổ (exploding).

Kiến trúc cốt lõi của mô hình Transformer bao gồm ba thành phần nền tảng:

1. **Multi-Head Self-Attention (Cơ chế chú ý đa đầu):** Cho phép mô hình tự động học và gán các trọng số liên kết ngữ cảnh giữa các cặp phần tử bất kỳ trong chuỗi dữ liệu lịch sử tài chính.
2. **Position-Wise Feed-Forward Network (Mạng lan truyền thẳng theo vị trí):** Một cấu trúc mạng neural liên kết đầy đủ (Fully-Connected) được áp dụng đồng nhất và độc lập tại từng vị trí thời gian trong chuỗi, bổ sung tính phi tuyến tính sâu (Non-linearity) để mô hình hóa hành vi biến động giá phức tạp.

3. **Positional Encoding (Mã hóa vị trí):** Vì bản chất Transformer xử lý song song và không có tính tuần tự, mô hình cần bổ sung thông tin định vị thời gian thông qua việc tích hợp các hàm sóng hình sin và cosin với tần số khác nhau vào vector nhúng đầu vào.

Cơ chế Self-Attention (Tự chú ý)

Self-Attention Mechanism đóng vai trò là hạt nhân vận hành của Transformer, chịu trách nhiệm định lượng hóa mức độ liên quan ngữ cảnh giữa các bước thời gian khác nhau. Toán học của cơ chế Scaled Dot-Product Attention được cấu thành từ ba ma trận đặc trưng biến đổi tuyến tính: Query (Q), Key (K), và Value (V).

Công thức xác định ma trận trọng số chú ý đầu ra được biểu diễn như sau:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

Trong đó:

- Q (Query): Ma trận truy vấn câu hỏi, kích thước $n \times d_k$.
- K (Key): Ma trận chìa khóa so khớp thông tin, kích thước $n \times d_k$.
- V (Value): Ma trận giá trị chứa thông tin ngữ cảnh, kích thước $n \times d_v$.
- d_k : Số chiều không gian của ma trận Key/Query, đóng vai trò làm hệ số tỷ lệ hạ bậc nhằm ngăn chặn giá trị tích vô hướng quá lớn đẩy hàm Softmax vào vùng bão hòa đạo hàm.
- n : Chiều dài của chuỗi thời gian đầu vào (lookback window).

Các ma trận không gian đặc trưng Q , K , V được thiết lập bằng cách nhân ma trận dữ liệu đầu vào X (kích thước $n \times d_{model}$) với ba ma trận trọng số khả vi tương ứng W^Q , W^K , và W^V :

$$Q = XW^Q, \quad K = XW^K, \quad V = XW^V$$


Để tối ưu hóa năng lực biểu diễn dữ liệu phi cấu trúc phức tạp, cơ chế Chú ý đa đầu (Multi-Head Attention) phân tách không gian thành h nhánh độc lập, thực thi tính toán Attention song song và tiến hành liên kết chuỗi (concatenate) các ma trận đầu ra:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h)W^O$$

$$\text{trong đó: } \text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

Kiến trúc Transformer Encoder-Decoder trong dự báo chuỗi thời gian

Đối với bài toán dự báo dịch chuyển xu hướng ngắn hạn của tài sản số Bitcoin, mô hình học sâu được thiết lập theo cấu trúc lai ghép Encoder-Decoder hoàn chỉnh:



Hình 2.1: Cấu trúc luồng Transformer Encoder-Decoder áp dụng cho chuỗi thời gian tài chính

- **Khối Encoder (Mã hóa):** Nhận đầu vào là chuỗi ma trận lịch sử chứa thông tin OHLCV kết hợp các chỉ số phái sinh kỹ thuật $X = [x_1, x_2, \dots, x_T]$ với độ dài chu kỳ T (thường thiết lập cửa sổ nhìn lại trong khoảng 24–72 giờ). Khối Encoder gồm nhiều phân tầng xếp chồng (thường 6–12 lớp), mỗi lớp bao gồm: Multi-Head Self-Attention, Position-Wise Feed-Forward Network, Residual Connection, và Layer Normalization. Output là vector trạng thái ẩn chiều cao $H = [h_1, h_2, \dots, h_T]$ mang thông tin tổng hòa về xu thế thị trường.
- **Khối Decoder (Giải mã):** Sử dụng cơ chế Chú ý chéo (Cross-Attention) để liên kết thông tin ẩn từ Encoder, đồng thời áp dụng Masked Multi-Head Attention nhằm ngăn chặn hiện tượng rò rỉ dữ liệu tương lai (Data Leakage) trong quá trình huấn luyện chuỗi. Decoder cũng có kiến trúc nhiều lớp tương tự Encoder. Output cuối cùng từ Decoder được đưa qua một tầng Tuyến tính kết hợp hàm kích hoạt Softmax nhằm kết xuất xác suất phân loại nhị phân dự báo xu hướng giá.

So sánh hiệu suất kiến trúc: Transformer vs LSTM

Việc thay thế mạng LSTM [9] bằng kiến trúc Transformer thế hệ mới được luận giải một cách định lượng thông qua các đặc tính kỹ thuật kiểm thử tại Bảng 2.1:

Bảng 2.1: Bảng so sánh thuộc tính kỹ thuật giữa LSTM và Transformer

Đặc tính phân tích	Mạng hồi quy LSTM	Kiến trúc Transformer
Cơ chế xử lý chuỗi	Tuần tự từng bước thời gian (Sequential)	Song song toàn bộ chuỗi (Parallelization)
Tốc độ huấn luyện mạng	Chậm, không tối ưu hóa trên cấu trúc GPU	Cực kỳ nhanh (tăng hiệu suất từ 10–100x)
Nắm bắt phụ thuộc dài hạn	Giới hạn dưới 100 chu kỳ (Long-term decay)	Tối ưu hóa tuyệt đối dựa trên Attention Weights
Độ ổn định luồng Gradient	Dễ rơi vào trạng thái tiêu biến đạo hàm	Luôn ổn định nhờ Skip Connections
Độ phức tạp bộ nhớ RAM	Tuyến tính với độ dài chuỗi $\mathcal{O}(N)$	Hàm bậc hai theo độ dài chuỗi $\mathcal{O}(N^2)$

2.1.2 Mô hình ngôn ngữ lớn BERT trong phân tích cảm xúc văn bản tin tức

Tổng quan về mô hình BERT

BERT (Bidirectional Encoder Representations from Transformers) được công bố bởi Devlin et al. (2019) [7] đã thiết lập một tiêu chuẩn học thuật mới trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP). Điểm cách mạng của BERT nằm ở cơ chế tiền huấn luyện hai chiều (Deep Bidirectional) dựa trên khối Transformer Encoder, cho phép mô hình thu giữ đồng thời ngữ cảnh của một từ dựa trên toàn bộ các từ xuất hiện cả phía trước và phía sau nó trong câu văn tiêu đề báo chí.

BERT được pre-train trên một lượng văn bản khổng lồ (2.5 tỷ token từ Wikipedia và 800 triệu token từ BookCorpus), tức là tổng cộng ≈ 3.3 tỷ token, cho phép mô hình học được những biểu diễn ngôn ngữ toàn diện và chính xác.

Kiến trúc và cơ chế Fine-tuning phục vụ Sentiment Analysis

Đề tài kế thừa mô hình pre-trained BERT-Base với quy mô cấu trúc gồm:

- 12 lớp Transformer Encoder
- Kích thước trạng thái ẩn (Hidden Size): $d_{model} = 768$
- Số đầu chú ý: 12 đầu độc lập
- Tổng số tham số khả vi: 110 triệu tham số

Để chuyển đổi BERT sang tác vụ định lượng hóa tâm lý thị trường, phương pháp Tinh chỉnh chuyên biệt (Fine-tuning) được áp dụng nghiêm ngặt:

1. Trích xuất vector trạng thái ẩn đầu ra của token đặc biệt [CLS] (đứng tại vị trí đầu tiên của chuỗi tiêu đề đầu vào), ký hiệu là $h_{[CLS]} \in \mathbb{R}^{768}$. Đây là vector đại diện cô đọng ngữ nghĩa toàn diện của văn bản tin tức.
2. Tích hợp một tầng Tuyến tính phân loại (Linear Classification Layer) ánh xạ trực tiếp từ không gian ẩn xuống không gian phân lớp cảm xúc tài chính (Tích cực, Trung lập, Tiêu cực):

$$\text{Output Probabilities} = \text{softmax}(W_{class} \cdot h_{[CLS]} + b_{class})$$

3. Tiến hành huấn luyện cập nhật trọng số có chọn lọc trên tập dữ liệu tiêu đề tin tức chuyên ngành Crypto nhằm tối ưu hóa hàm lỗi Entropy chéo trong vòng 3-5 epochs, đạt độ chính xác phân loại ngữ cảnh chuyên sâu vượt ngưỡng 90%.

2.1.3 Attention Fusion Layer: Tích hợp đồng bộ tín hiệu đa phương thức

Để thiết lập mối liên kết hữu cơ giữa đặc trưng kỹ thuật phi tuyến tính trích xuất từ chuỗi nền giá tài chính ($H_{tech} \in \mathbb{R}^{T \times d_{model}}$) và chỉ báo tâm lý định lượng từ luồng tin tức vĩ mô ($H_{sentiment} \in \mathbb{R}^{1 \times d_{model}}$), đề tài đề xuất lớp Tích hợp dựa trên cơ chế chú ý (Attention-based Fusion Layer).

Lớp Fusion Layer tiến hành xác định ma trận trọng số đóng góp động (Dynamic Attention Weights) phản ánh mối tương quan trực tiếp giữa trạng thái tâm lý văn bản và hành vi kỹ thuật thị trường tài sản số:

$$\alpha = \text{softmax} \left(\frac{H_{sentiment} \cdot H_{tech}^T}{\sqrt{d_{model}}} \right)$$

Vector đặc trưng tích hợp toàn diện cuối cùng (H_{fused}) được xác lập thông qua tích có trọng số động:

$$H_{fused} = \alpha \cdot H_{tech} + (1 - \alpha) \cdot \text{Pooling}(H_{tech})$$

Giải pháp này cho phép hệ thống mạng học sâu tự động điều chỉnh hành vi dự báo: ưu tiên phân tích các chỉ báo kỹ thuật trong các khung giờ giao dịch bình ổn, và lập tức chuyển dịch trọng số chú ý cao độ sang chỉ số cảm tính văn bản khi xuất hiện các cú sốc thông tin lớn (FUD/FOMO) lan truyền trên các cổng báo chí.

2.2 Xây dựng và mô tả chi tiết bộ dữ liệu

2.2.1 Nguồn gốc và quy trình thu thập dữ liệu

Dữ liệu chuỗi thời gian OHLCV từ sàn Binance

Dữ liệu chỉ số kỹ thuật gốc được khai thác trực tiếp từ sàn Binance công khai thông qua API tài liệu lịch sử [2]. Khoảng thời gian nghiên cứu được xác định đồng bộ từ ngày ****01/01/2024 đến ngày 01/07/2026**** (chu kỳ 2 năm 6 tháng, tương đương 913 ngày).

Nhằm mục đích nắm bắt nhạy bén các hành vi dịch chuyển và tín hiệu nhiễu ngắn hạn, tần suất trích xuất dữ liệu được cấu hình cố định ở mức độ phân giải 1 giờ (Hourly Candle). Cặp tài sản mục tiêu là **BTC/USDT**.

Toán học xác định tổng số lượng khung giờ lý thuyết trên trục thời gian nghiên cứu:

$$\text{Tổng số giờ lý thuyết} = 913 \text{ ngày} \times 24 \text{ giờ/ngày} = 21,912 \text{ giờ}$$

Do sàn Binance hoạt động 24/7 liên tục không có ngày nghỉ thị trường, dữ liệu thu thập được bảo toàn gần như trọn vẹn. Tuy nhiên, sau giai đoạn loại bỏ các khung thời gian mất kết nối hoặc dữ liệu khuyết do lỗi API truyền thông (chiếm tỷ lệ cực nhỏ $< 0.3\%$, tương đương khoảng 62 bản ghi), bộ dữ liệu ghi nhận chính xác ****21,850 bản ghi chuỗi thời gian sạch****.

Dữ liệu tiêu đề văn bản từ các cổng tin tức chuyên ngành

Song song với dữ liệu giá số, hệ thống kích hoạt module Web Crawler thu thập tự động toàn bộ luồng tiêu đề tin tức báo chí xuất hiện trong cùng khung thời gian 2 năm 6 tháng từ 3 cổng thông tin điện tử có tầm ảnh hưởng lớn nhất thị trường tài sản mã hóa: CoinDesk [3], Cointelegraph [6], và The Block [12].

Quy trình xử lý thu thập bao gồm:

1. Sử dụng framework BeautifulSoup quét dữ liệu hàng giờ từ các cổng tin
2. Áp dụng các bộ lọc từ khóa định danh tài sản số nhằm loại bỏ tin nhiễu vĩ mô không liên quan

3. Lưu trữ tiêu đề + timestamp + nguồn gốc

Tổng số lượng tiêu đề văn bản thô thu thập được ghi nhận là **1,842 tiêu đề tin tức chính thống** trong khoảng thời gian này.

2.2.2 Quy trình tiền xử lý dữ liệu (Data Preprocessing Pipeline)

Xử lý luồng dữ liệu số OHLCV

1. **Khắc phục bản ghi khuyết thiếu:** Các hàng dữ liệu trống do sự cố nghẽn mạng API (chiếm tỷ lệ cực nhỏ $< 0.3\%$, tương đương khoảng 62 bản ghi trống trong tổng số 21,912 giờ) được bù đắp dữ liệu bằng phương pháp nội suy tuyến tính (Linear Interpolation) dựa trên các bước thời gian liền kề, bảo đảm tính liên tục toàn vẹn cho chuỗi thời gian Transformer.

- Trước xử lý: 21,912 bản ghi
- Sau xử lý: 21,850 bản ghi (mất 62 bản ghi, tỷ lệ 0.28%)

2. **Lọc giá trị bất thường (Outliers):** Sử dụng phương pháp Biên khoảng tứ phân vị (Interquartile Range - IQR) để phát hiện và cô lập các điểm dữ liệu nhiễu cực đoan phát sinh do lỗi hệ thống dữ liệu. Công thức:

$$\text{Khoảng chấp nhận} = [Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR]$$

Các giá trị nằm ngoài khoảng này được xóa hoặc thay thế bằng giá trị giới hạn (clamping).

3. **Chuẩn hóa biên độ (Min-Max Normalization):** Để triệt tiêu sự lệch biệt về đơn vị đo lường và biên độ lớn giữa mức giá Bitcoin (100,000 USD), khối lượng giao dịch, và các chỉ báo kỹ thuật, toàn bộ các thuộc tính số được chuẩn hóa tuyến tính về miền không gian $[0, 1]$:

$$x_{scaled} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

4. **Cấu trúc hóa chỉ báo kỹ thuật tài chính:** Từ 5 trường thông tin OHLCV gốc, hệ thống thực hiện trích xuất thêm 11 chỉ số phái sinh kỹ thuật bao gồm:

- RSI (Relative Strength Index) với khung 14 giờ
- MACD (Moving Average Convergence Divergence) với tham số (12, 26, 9)
- Bollinger Bands với biên độ 2 độ lệch chuẩn
- Bộ ba đường trung bình động lũy thừa EMA (7, 14, 21)

5. **Thiết lập biến mục tiêu (Labeling):** Biến mục tiêu dự báo xu hướng giá sau 24 giờ tiếp theo được định nghĩa dưới dạng nhãn nhị phân:

$$y_t = \begin{cases} 1 & \text{nếu } P_{t+24h} > P_t \text{ (Xu hướng tăng)} \\ 0 & \text{nếu } P_{t+24h} \leq P_t \text{ (Xu hướng giảm/ngang)} \end{cases}$$

Thống kê phân bố nhãn mục tiêu thực tế ghi nhận mức độ cân bằng lý tưởng:

- Nhãn 1 (tăng): 11,230 bản ghi (51.4%)
- Nhãn 0 (giảm): 10,620 bản ghi (48.6%)

Mức độ cân bằng này loại trừ hoàn toàn rủi ro mất cân bằng dữ liệu (Imbalanced Dataset).

Xử lý luồng văn bản tin tức tài chính

1. **Làm sạch cấu trúc văn bản:** Toàn bộ tiêu đề tin tức thô được gỡ bỏ các thẻ định dạng HTML, loại bỏ hệ thống ký tự đặc biệt phi cấu trúc (dấu câu, emoji, v.v.), đưa về ký tự thường (lowercase) và chuẩn hóa khoảng trắng.
2. **Định lượng chỉ số cảm xúc qua mô hình FinBERT/BERT:** Tiêu đề sau khi làm sạch được nạp trực tiếp vào pipeline xử lý ngôn ngữ dựa trên mô hình `distilbert-base-uncased-finetuned-sst-2-english` (FinBERT optimized version) để trích xuất phân phối xác suất trạng thái tâm lý trên 2 lớp (positive/negative) hoặc 3 lớp (positive/neutral/negative tùy model).

Điểm số cảm xúc tổng hợp (Sentiment Score) của một tiêu đề được lượng hóa về không gian $[-1, 1]$ theo công thức:

$$\text{Sentiment Score} = P_{\text{positive}} - P_{\text{negative}}$$

Ví dụ cụ thể:

- "SEC phê duyệt Bitcoin Spot ETF" $\rightarrow$ Sentiment = 0.95 (tích cực mạnh)
 - "FTX sàn giao dịch vỡ nợ 8 tỷ USD" $\rightarrow$ Sentiment = -0.90 (tiêu cực mạnh)
 - "Nhà khoa học phát triển công nghệ Blockchain mới" $\rightarrow$ Sentiment = 0.15 (trung lập)
3. **Đồng bộ hóa trục thời gian đa phương thức (Time-Alignment Fusion):** Chỉ số cảm xúc văn bản được tổng hợp và gộp theo khung giờ (Hourly Aggregation) để khớp nối chính xác với luồng dữ liệu OHLCV. Tại các khung giờ xuất hiện nhiều tiêu đề tin tức cùng lúc, điểm cảm xúc của giờ sẽ bằng trung bình cộng toán học các điểm tin tức thành phần:

$$\text{Sentiment}_{\text{hour}} = \frac{1}{M} \sum_{i=1}^M \text{Sentiment}_i$$

Đối với các khung giờ thị trường không ghi nhận bất kỳ dòng tin tức nào xuất hiện, chỉ số cảm xúc của giờ đó được gán giá trị mặc định bằng `**0.0**` (Trạng thái tâm lý hoàn toàn trung lập—không có tín hiệu mới), chứ không phải 0.5 (không biết).

2.2.3 Cấu trúc chi tiết không gian đặc trưng (Features Structure)

Bộ dữ liệu sạch tích hợp sau xử lý có cấu trúc bao gồm 17 trường thông tin cốt lõi, phục vụ làm đầu vào trực tiếp cho kiến trúc Two-Modal mạng học sâu (Bảng 2.2):

Bảng 2.2: Mô tả chi tiết cấu trúc không gian đặc trưng của bộ dữ liệu sạch

Mã danh định đặc trưng	Kiểu dữ liệu	Mô tả ý nghĩa ngữ nghĩa	Phân nhóm
Open	Float	Giá mở cửa nền giờ (USD)	OHLCV (Scaled)
High	Float	Giá cao nhất nền giờ (USD)	OHLCV (Scaled)
Low	Float	Giá thấp nhất nền giờ (USD)	OHLCV (Scaled)
Close	Float	Giá đóng cửa nền giờ (USD)	OHLCV (Scaled)
Volume	Float	Khối lượng giao dịch BTC	OHLCV (Scaled)
RSI_14	Float	Chỉ số sức mạnh tương đối	Chỉ báo phái sinh
MACD	Float	Đường MACD chính	Chỉ báo phái sinh
MACD_Signal	Float	Đường tín hiệu MACD	Chỉ báo phái sinh
MACD_Hist	Float	Biểu đồ MACD	Chỉ báo phái sinh
BB_Upper	Float	Biên Bollinger Bands trên	Chỉ báo phái sinh
BB_Middle	Float	Đường giữa Bollinger Bands	Chỉ báo phái sinh
BB_Lower	Float	Biên Bollinger Bands dưới	Chỉ báo phái sinh
EMA7	Float	Trung bình động 7 giờ	Chỉ báo phái sinh
EMA14	Float	Trung bình động 14 giờ	Chỉ báo phái sinh
EMA21	Float	Trung bình động 21 giờ	Chỉ báo phái sinh
Hourly_Sentiment	Float	Điểm cảm xúc tin tức giờ	Đặc trưng NLP
Target (y)	Binary	Hướng dịch chuyển giá 24h	Biến mục tiêu

2.2.4 Thống kê và Phân chia phân lớp bộ dữ liệu

Thống kê tổng thể thuộc tính cơ lý vật lý của Dataset sạch sau tiền xử lý được cô đọng tại Bảng 2.3:

Bảng 2.3: Bảng thống kê định lượng tổng thể bộ dữ liệu sạch

Thông số định lượng thuộc tính	Giá trị thống kê thực tế
Tổng số lượng bản ghi chuỗi thời gian (mẫu giờ)	21,850
Tổng số lượng tiêu đề báo chí văn bản tích hợp	1,842
Tổng số lượng chiều không gian đặc trưng đầu vào (Features)	17
Mốc biên độ thời gian khảo sát	01/01/2024 – 01/07/2026
Độ phân giải chu kỳ thời gian	1 giờ (Hourly)
Tỷ lệ mẫu nhân tăng giá ($y = 1$)	11,230 (51.4%)
Tỷ lệ mẫu nhân giảm giá ($y = 0$)	10,620 (48.6%)
Tổng dung lượng bộ nhớ vật lý Dataset	~ 15.2 MB (.csv format)

Để ngăn chặn tuyệt đối hiện tượng rò rỉ dữ liệu tương lai vào quá khứ (Data Leakage)—lỗi thường gặp và nghiêm trọng nhất trong dự báo tài chính—phương pháp chia tách dữ liệu ngẫu nhiên (Random Shuffle Split) hoàn toàn bị loại bỏ. Thay vào đó, đề tài áp dụng cơ chế ****Chia tách chuỗi thời gian tuyến tính (Time-Series Chronological Split)**** để đảm bảo tính thực tế của bài toán kinh doanh đầu tư: mô hình chỉ học từ dữ liệu quá khứ và dự báo trên dòng thời gian tương lai độc lập. Bộ dữ liệu được cấu hình chia cắt theo tỷ lệ nghiêm ngặt 70/15/15:

- **Tập huấn luyện (Training Set):** Chiếm 70% khối lượng dòng thời gian, trải dài từ ngày **01/01/2024 đến 01/01/2026** (2 năm)
 - Số bản ghi: 15,295 (70%)
 - Vai trò: Tối ưu hóa hệ thống trọng số ma trận của mạng học sâu

- **Tập kiểm định (Validation Set):** Chiếm 15% thời gian, kéo dài từ ngày **01/01/2026 đến 01/04/2026** (3 tháng)
 - Số bản ghi: 3,277 (15%)
 - Vai trò: Tinh chỉnh siêu tham số (Hyperparameters tuning) và ngăn chặn quá khớp (Overfitting)
- **Tập kiểm thử độc lập (Test Set):** Chiếm 15% thời gian cuối cùng, kéo dài từ ngày **01/04/2026 đến 01/07/2026** (3 tháng)
 - Số bản ghi: 3,278 (15%)
 - Vai trò: Đánh giá khách quan hiệu suất mô hình trên vùng dữ liệu chưa từng tiếp xúc

Kiểm chứng: $15,295 + 3,277 + 3,278 = 21,850$ ✓

Mặc dù tỷ lệ nhãn đầu vào đạt trạng thái cân bằng lý tưởng (51.4% vs 48.6%), trong quá trình huấn luyện lan truyền ngược, hệ thống vẫn tích hợp hàm lỗi Binary Cross-Entropy có trọng số điều chỉnh động (Weighted BCE Loss) kết hợp tối ưu hóa tham số mạng nhằm triệt tiêu tối đa các thiên kiến cục bộ nhỏ nhất của thị trường tài sản số:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [\beta \cdot y_i \cdot \log(\hat{y}_i) + (1 - \beta) \cdot (1 - y_i) \cdot \log(1 - \hat{y}_i)]$$

Với hệ số trọng số cân bằng lớp $\beta = 1.0$ do sự phân bố cân xứng tự nhiên của tập dữ liệu sạch.

Tài liệu tham khảo

- [1] Zainab Alameer, Muhammad Khurram Mirza, Amir Hussain, et al. Multistep-ahead forecasting of crude oil prices using neural networks. *IEEE Access*, 9:105589–105597, 2021.
- [2] Binance. Binance public data: Historical market data archive and collection. Accessed: 2026-07-02.
- [3] CoinDesk. Bitcoin price index and cryptocurrency news. Accessed: 2026-07-02.
- [4] CoinGecko. Coingecko api: World’s largest independent crypto data aggregator. Accessed: 2026-07-02.
- [5] CoinMarketCap. Coinmarketcap api documentation: The industry authority for cryptocurrency data, 2026. Accessed: 2026-07-02.
- [6] Cointelegraph. Cryptocurrency news and analysis. Accessed: 2026-07-02.
- [7] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2019.
- [8] Alec Go, Richa Bhayani, and Lei Huang. Twitter sentiment classification using distant supervision. *CS224N Report, Stanford University*, 2009.
- [9] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.
- [10] Christopher Krauss, Xuan Anh Do, and Nicolas Huck. Deep neural networks, gradient-based optimization for forex prediction. *Decision Support Systems*, 100:1–14, 2017.
- [11] David M. K. Nelson, Adam C. M. Pereira, and Reynaldo A. de Oliveira. Stock market’s price movement prediction with lstm neural networks. *2017 International Joint Conference on Neural Networks (IJCNN)*, pages 1419–1426, 2017.
- [12] The Block. Crypto research and data platform. Accessed: 2026-07-02.
- [13] Triple-A. Global crypto adoption report 2025, 2025. Accessed: 2026-07-02.
- [14] Ashish Vaswani, Noam Shazeer, Niki Parmar, et al. Attention is all you need. *Advances in Neural Information Processing Systems*, 30:5998–6008, 2017.